

STAT3888 · SPATIOTEMPORAL DATA SCIENCE

Toronto Bicycle Theft

五分钟演讲稿与方法原理解析

使用方式

Part I 可以直接照着练习；Part II 用于真正理解基函数回归；Part III 用于答辩前快速复习。

姓名：_____

学号：_____

项目范围：Task 1 时空可视化 + Task 4 基函数线性回归

正式时长：5 分钟（含指图、停顿和约 5 秒视频展示）

数据：Toronto bicycle theft reports, 2014–2023, 31,833 条事件, 140 个社区

评分安全线

Basis OLS 是 Task 4 标准模型；**Basis Ridge** 是稳定化扩展。 R^2 不是准确率，空间相关不是因果。

使用说明与五分钟路线图

先完整朗读两遍。第三遍打开 PPT，只在“指图动作”规定的位置指图，不要逐字朗读坐标轴或图题。

PPT	时间	任务	必须让听众记住
第 1 页	0:00–1:10	研究问题与时间证据	盗窃具有重复的温暖季节高峰，同时峰值强度随年份发生长期变化。
第 2 页	1:10–2:15	空间热点与时空共同变化	季节强度会变化，但报告盗窃长期集中在 downtown neighbourhoods。
第 3 页	2:15–4:05	Task 4: 基函数线性回归	基函数让线性模型表达非线性的时间、季节和空间结构，Ridge 则提高系数稳定性。
第 4 页	4:05–5:00	预测、残差与结论	模型捕捉了主要时空结构，但对极端峰值的低估仍是最重要的局限。

计时建议

英文正式稿共 659 词。以每分钟约 132 词的清晰学术语速，加上指图和约 5 秒视频停顿，约为 5 分钟。

正式演讲必须保持的四个区分

- Task 1 负责发现和展示模式；Task 4 负责建立预测模型。
- Basis OLS 满足任务要求；Basis Ridge 是在同一线性模型上的 L2 正则化扩展。
- OLS 测试 RMSE 最低；Ridge 强调系数稳定性，不能说 Ridge 在所有指标上最好。
- reported theft counts 是报告数量，不等于真实风险，也不证明因果关系。

Part I · 五分钟逐页演讲稿（English）


下列内容按最终四页 PPT 排列。方括号中的动作不需要说出口。

第 1 页 · 研究问题与时间证据 | 0:00–1:10

Toronto thefts peak in summer and downtown

How do bicycle thefts vary over time and across Toronto?

31,833 incidents · 140 areas · 2014–2023



TEMPORAL SIGNAL

Thefts follow a strong annual cycle—July averages about 500 reports, while winter activity falls below 100. So basically, the thieves were more likely to steal bikes in summer.

1

指图动作

先指左侧时间序列中的多个夏季尖峰；说到季节循环时转向右侧月份分布；最后停在底部结论框。

Good morning. My project studies reported bicycle thefts in Toronto from 2014 to 2023. The raw data contain 31,833 incidents across 140 neighbourhoods. I aggregated these events into a neighbourhood-by-month panel, where each row records the number of reported thefts in one neighbourhood during one month. This structure lets us study temporal change and spatial variation together. On the left, the citywide monthly series shows repeated sharp peaks, mostly during the warmer part of each year. However, the peak height is not constant across years, so the data contain both a seasonal cycle and longer-run change. The monthly distribution on the right confirms that the typical count rises from winter into summer and then falls toward the end of the year. The main message from this slide is that Toronto bicycle theft is seasonal, but the strength of the seasonal peak changes over time.


本页核心句

盗窃具有重复的温暖季节高峰，同时峰值强度随年份发生长期变化。

第 2 页 · 空间热点与时空共同变化 | 1:10–2:15

Downtown Toronto remains the theft hotspot

Waterfront 27.6/month · Bay Street 22.4 · Church-Yonge 20.0 · Top three = 26.4% of all incidents



指图动作

沿热力图横向指时间、纵向指社区；随后指右上地图的 downtown 高值区；视频只播放约 5 秒，用一句话概括，不等待完整播放。

Slide two adds the spatial dimension and completes the required Task 1. In the space-time heatmap, each row is one high-count neighbourhood, each column is one month, and brighter colours indicate more reported thefts. Many rows brighten during similar months, showing that the seasonal peak is not an isolated event in only one area. At the same time, the brightest cells remain concentrated in a relatively small group of neighbourhoods. The map at the upper right returns these long-run averages to their geographic locations and shows that the main hotspots are concentrated around downtown Toronto. The short animation below shows how the pattern changes month by month from 2014 to 2023. Hotspot intensity rises and falls, but the broad spatial ordering remains persistent. Therefore, Task 1 provides two connected findings: a warm-season temporal peak and a stable downtown spatial concentration.


本页核心句

季节强度会变化，但报告盗窃长期集中在 **downtown neighbourhoods**。

第 3 页 · Task 4: 基函数线性回归 | 2:15–4:05

Basis functions encode time and space

Count → log1p → temporal + seasonal + spatial bases → OLS / Ridge Train 2014–2021 → Validate 2022 → Test 2023



3

指图动作

依次指左侧 B-spline、周期波形和空间基函数；说到测试结果时指右侧 OLS 与 Ridge 两行；不要把 R^2 读成“75.7%的预测准确率”。


I then address Task 4 by building a linear regression model with basis functions. The response is the monthly theft count for each neighbourhood. Because a small number of neighbourhood-months have very high counts, I model log one plus the count. This reduces the influence of extreme peaks while preserving zero observations. The model is still linear in its coefficients, but the design matrix contains transformed features rather than only raw time and coordinates. First, cubic B-splines represent smooth long-run change using several local curves. Second, sine and cosine terms represent annual and half-year seasonal cycles. Third, sixteen radial basis functions, or RBFs, convert distance from selected spatial centres into smooth measures of proximity. I also retain neighbourhood indicators to capture persistent area differences. In other words, the basis functions convert nonlinear time, seasonal, and spatial patterns into columns of a design matrix, and the regression forms a linear combination of those columns. The split is strictly chronological to avoid future information leakage: 2014 to 2021 are used for training, 2022 is used to choose the Ridge penalty, and 2023 is held out for final testing. Basis OLS is the standard basis-function linear regression required by Task 4. Basis Ridge uses the same design matrix but adds a squared-coefficient penalty, which stabilises coefficients when basis columns are correlated; it is not a separate black-box model. On the 2023 test set, Basis OLS has an RMSE of 2.05 and an R-squared of 0.757. Basis Ridge has an RMSE of 2.06 and an R-squared of 0.754. Their predictive performance is almost identical. The selected lambda is only 0.0001, so the validation procedure indicates that only very weak regularisation is needed.

本页核心句

基函数让线性模型表达非线性的时间、季节和空间结构，**Ridge** 则提高系数稳定性。

第 4 页 · 预测、残差与结论 | 4:05–5:00

Seasonality is captured, but peaks are missed



4

指图动作

先指实际与预测曲线的共同周期，再指被压低的高峰；最后指残差图和底部结论。

The final slide checks what the model actually learned. The observed and Ridge prediction curves share the main annual cycle, and both basis models clearly outperform the citywide-mean and neighbourhood-mean baselines. However, the largest summer peaks are still underestimated. The residual map also shows that most neighbourhood errors are modest, while extreme months and a small number of hotspots remain the main difficulty. Overall, the project completes Task 1 and Task 4: the visualisations identify warm-season peaks and persistent downtown concentration, while basis-function regression combines long-run, seasonal, and spatial signals in one interpretable predictive framework. Finally, these are associations in reported theft counts. They do not establish a causal effect of season or location on bicycle theft. Thank you.

本页核心句

模型捕捉了主要时空结构，但对极端峰值的低估仍是最重要的局限。

Part II · 方法原理解析

每个概念都按“直觉 → 数学表达 → 本项目如何实现 → 为什么适合”展开。先理解直觉，再看公式中的每个符号。

1. 为什么建立 neighbourhood-month 面板

直觉：原始数据的一行是一宗盗窃事件，不能直接回答“某社区某月有多少宗”。面板化把事件按社区和月份计数，并为没有事件的组合补零，使所有社区拥有同一条时间轴。

数学表达

y_{it} = 社区 i 在月份 t 的报告盗窃次数。

本项目如何实现：140 个社区乘 120 个月得到 16,800 行；每行同时包含 y_{it} 、经纬度、时间索引、月份和年份。

为什么适合：响应变量、时间位置和空间位置被放入同一观察单位，才能统一完成时空可视化和预测。

2. 三种时空可视化分别做什么

直觉：趋势图回答“什么时候高”；热点图回答“哪里高”；时空热力图和动画回答“哪里在什么时候变高”。三者互补，不能相互替代。

数学表达

趋势： $\sum_t y_{it}$ ；长期热点：平均 $_t(y_{it})$ ；热力图单元格： y_{it} 。

本项目如何实现：Slide 1 展示月度总量和月份分布；Slide 2 展示 25 个高值社区的热力图、社区地图和 2014–2023 动画。

为什么适合：评分标准把 Task 1 单独计为 30%，因此必须从时间、空间和联合时空三个角度提供证据。

3. 为什么使用 $\log(1+y)$

直觉：计数分布右偏：大多数社区月份计数较低，少数热点月份特别高。直接最小化平方误差时，大值会被平方后放大，模型容易被少数峰值支配。

数学表达

$z = \log(1+y)$ ，预测后用 $\hat{y} = \max(0, \exp(\hat{z})-1)$ 返回计数尺度。

本项目如何实现：OLS 和 Ridge 都在 $\log_{1p}$ 尺度拟合，但 MAE、RMSE 和 R^2 全部在原始盗窃次数尺度计算。

为什么适合：它保留零值、压缩高值并让误差更均衡；代价是反变换可能产生偏差，峰值也更容易被低估。

4. 设计矩阵如何连接高等代数

直觉：把每个观测转成一行特征，把每个基函数转成一列，就得到矩阵 X 。预测就是 X 的各列按系数 β 做线性组合。

数学表达

$$z = X\beta + \varepsilon; \text{第 } j \text{ 列是基函数 } \varphi_j, \hat{z}_i = \beta_0 + \sum_j \beta_j \varphi_j(x_i)。$$

本项目如何实现： X 包含时间 B-spline、4 个周期基函数、16 个空间 RBF 和 140 个社区指示变量。

为什么适合：非线性来自 φ_j 的形状，而参数 β 仍然线性，因此可以沿用线性代数中的矩阵乘法和最小二乘。

5. B-spline 如何表达长期变化

直觉：一条直线只能表示固定斜率，无法同时表示上升、下降和转折。B-spline 使用多条局部平滑曲线覆盖时间轴，模型把它们叠加成整体趋势。

数学表达

$$f(t) = \sum_k \beta_k B_k(t), \text{其中 } B_k(t) \text{ 是三次 B-spline 基函数。}$$

本项目如何实现：训练期时间索引的 20%、40%、60%、80% 分位数作为 4 个内部结点，边界覆盖 1 到 120 月。

为什么适合：它比高阶多项式更局部、更稳定，也比为每个月单独设置参数更平滑、更节省自由度。

6. sine/cosine 为什么能表示季节性

直觉：一年后月份会回到同一季节，因此季节不是单向趋势，而是循环。正弦和余弦天然首尾相接，并能通过不同系数组合改变峰值出现的月份。

数学表达

$$\sin(2\pi m/12)、\cos(2\pi m/12) \text{ 表示一年周期；} \sin(4\pi m/12)、\cos(4\pi m/12) \text{ 表示半年谐波。}$$

本项目如何实现： m 是 1 到 12 的月份编号，四列周期特征与长期 B-spline 同时进入模型。

为什么适合：它用很少的参数表达平滑重复循环，并避免把 12 个月当作彼此毫无关系的类别。

7. RBF 如何把空间距离变成特征

直觉：经纬度本身只给出坐标；RBF 改问“这个社区离某个空间中心有多近”。越靠近中心，该基函数的值越接近 1，越远则平滑下降到 0。

数学表达

$$\phi_k(s) = \exp(-\|s - c_k\|^2 / (2\sigma^2))。$$

本项目如何实现：从 140 个社区中均匀选取 16 个中心，标准化经纬度后使用 $\sigma=0.8$ 生成 16 列空间特征。

为什么适合：RBF 提供平滑的空间邻近表达；相邻社区可以共享信息，而不是只依赖硬边界。

8. Basis OLS 的目标是什么

直觉：OLS 寻找一组系数，使所有训练观测的实际 log 计数与预测 log 计数之间的平方距离最小。

数学表达

$$\beta_{OLS} = \operatorname{argmin}_{\beta} \|z - X\beta\|^2。$$

本项目如何实现：模型使用 2014–2022 数据拟合 OLS，再对完全未参与拟合的 2023 年进行预测。

为什么适合：这是 Task 4 最直接、可解释的基函数线性回归；每个系数对应一系列基函数的贡献。

9. Ridge 为什么更稳定

直觉：相邻 B-spline、相近 RBF 和社区指示变量可能携带相似信息，导致不同列相关。OLS 仍可预测，但系数可能对样本小变化非常敏感。Ridge 允许增加一点训练误差，换取更小、更稳定的系数。

数学表达

$$\beta_{Ridge} = \operatorname{argmin}_{\beta} \{\|z - X\beta\|^2 + \lambda \|\beta\|_2^2\}。$$

本项目如何实现：在 2022 验证集上从 100 到 0.0001 比较 100 个 λ ，最终选择 $\lambda=0.0001$ ；然后使用 2014–2022 重新拟合，并在 2023 测试。

为什么适合：Ridge 仍属于线性回归，只增加 L2 惩罚；本项目很小的 λ 解释了其结果为何与 OLS 几乎相同。

10. 为什么必须按时间切分并使用基线

直觉：随机切分会让未来月份进入训练集，相当于提前看到答案。按时间切分才模拟真实任务：用过去预测未来。基线则回答复杂模型是否真的比简单规则更好。

数学表达

$$MAE = \operatorname{mean}|y - \hat{y}|; RMSE = \sqrt{\operatorname{mean}((y - \hat{y})^2)}; R^2 = 1 - \Sigma(y - \hat{y})^2 / \Sigma(y - \bar{y})^2。$$

本项目如何实现：2014–2021 训练、2022 验证、2023 测试；比较 Global mean、Neighbourhood mean、Basis OLS 和 Basis Ridge。

为什么适合：测试集只使用一次，指标更接近未来泛化能力；同时简单基线让性能提升具有可解释参照。

模型结果应如何准确表述

模型	MAE	RMSE	R ²	正确解释
Global mean	2.187	4.167	-0.007	比测试集均值还差

模型	MAE	RMSE	R ²	正确解释
Neighbourhood mean	1.411	2.726	0.569	有空间差异但无时间变化
Basis OLS	1.008	2.048	0.757	最低 RMSE、最高 R ²
Basis Ridge	1.006	2.060	0.754	最低 MAE、系数更稳定

推荐说法

Basis OLS 在 2023 测试集取得最低 RMSE 2.05 和最高 R² 0.757；Basis Ridge 结果几乎相同，并在相关基函数下提供稳定化，因此作为主要预测与残差展示模型。

一分钟原理复述

- 先把单条事件汇总为社区-月份计数，使时间和空间进入同一观察单位。
- 用趋势图、热点图、热力图和动画分别回答什么时候高、哪里高、哪里在什么时候变高。
- 用 $\log(1+y)$ 压缩极端计数，再在预测后返回原始计数尺度评价。
- 用 B-spline、sine/cosine 和 RBF 把长期、季节和空间结构变成设计矩阵的列。
- Basis OLS 完成 Task 4；Basis Ridge 在同一线性模型上加入 L2 惩罚以提高稳定性。
- 按时间划分训练、验证和测试，并与简单基线比较，才能说明模型对未来数据是否真正有用。

Part III · 答辩速查

先回答“20秒版本”。只有老师继续追问时，再使用“进一步解释”。

1. 为什么选择自行车盗窃数据？

20秒回答

它同时包含日期、社区和经纬度，能够自然形成社区-月份面板，既适合 Task 1 的时空可视化，也适合 Task 4 的基函数回归。

进一步解释：数据覆盖 10 年和 140 个社区，时间长度足以识别长期与季节变化，空间单元数量也足以构造热点图和空间 RBF，同时研究问题容易用领域语言解释。

2. 为什么不用随机训练测试切分？

20秒回答

因为目标是用过去预测未来，随机切分会把未来信息泄漏给训练过程。

进一步解释：项目按 2014–2021 训练、2022 验证、2023 测试；这样模型选择和最终评价的时间顺序与真实预测场景一致。

3. 这个项目是否真的满足 Task 4？

20秒回答

满足。Basis OLS 是在 B-spline、周期基函数和空间 RBF 扩展后的设计矩阵上拟合普通线性回归，Basis Ridge 是同一模型的正则化扩展。

进一步解释：关键是模型对参数 β 保持线性；输入经过非线性基函数转换并不改变“线性回归”这一点。

4. 为什么同时报告 OLS 和 Ridge？

20秒回答

OLS 直接对应 Task 4 要求，Ridge 用于处理基函数相关时的系数不稳定；报告两者能同时证明合规性和稳健性。

进一步解释：两者测试 RMSE 只差 0.01，验证集选择 $\lambda=0.0001$ ，表明本数据只需要很弱的惩罚。

5. $R^2=0.757$ 是否等于 75.7%的准确率？

20 秒回答

不是。它表示模型相对于测试集均值基准减少了约 75.7%的平方误差变异，不是分类正确率。

进一步解释： R^2 由残差平方和与总平方和的比例定义，在测试集上甚至可能为负；因此必须与 MAE 和 RMSE 一起解释。

6. 为什么要做 $\log(1+y)$ 而不是直接预测计数？

20 秒回答

它保留零值并压缩极端高计数，避免少数热点月份过度支配平方误差。

进一步解释：反变换后仍在原始计数尺度评价，但 $\log$ 变换和平方误差都会产生平滑效应，这也是高峰被低估的可能原因之一。

7. 为什么选 16 个空间 RBF 中心？

20 秒回答

16 个中心在表达空间平滑变化与控制模型复杂度之间提供了可管理的折中。

进一步解释：中心按已排序社区均匀抽取并在训练数据上定义；更多中心可能提高灵活性，但也增加相关性和过拟合风险。

8. 模型最大的不足是什么？

20 秒回答

它对最高夏季峰值仍有低估，而且把误差近似当作独立连续误差，没有显式建模计数分布和残余时空相关。

进一步解释：后续可比较 Poisson 或 negative-binomial 模型，并检查残差的时间和空间相关；但这些属于项目要求之外的后续改进。

9. 热点是否说明 downtown 导致盗窃？

20 秒回答

不能。地图显示的是 reported theft counts 的空间相关模式，不是因果效应。

进一步解释：人口、骑行量、停车设施和报告行为都可能同时影响计数；没有暴露量和因果设计时，不能把高计数直接解释成地理位置的因果作用或个体风险。

10. 为什么 Ridge 作为主模型但 OLS 的 RMSE 更低？

20 秒回答

两者 RMSE 只差 0.01，预测能力几乎相同；选择 Ridge 强调的是相关基函数下的系数稳定性，而不是声称它在这个测试集上数值最优。

进一步解释：正式报告应明确：OLS 取得最低 RMSE 和最高 R^2 ，Ridge 取得略低 MAE 并提供正则化稳定性。这样既准确又能解释模型选择。

上台前最后检查

- 能不看稿的情况下说出研究问题和两条核心发现。
- 能解释热力图的行、列和颜色分别代表什么。
- 能用“设计矩阵的列”解释基函数，而不是只背术语。
- 能说出训练、验证、测试年份及其目的。
- 能准确区分 OLS 与 Ridge 的结果和选择理由。
- 不会把 R^2 说成预测准确率，也不会把空间热点说成因果。