

STAT3888 自行车盗窃

时空基函数回归

从时空可视化到可信预测的完整项目手册

数据	bicycle.csv · 31,833条事件 · 140个社区 · 2014–2023
主线	Task 1 时空可视化 + Task 4 基函数线性回归
基础	从高等代数、概率论进入设计矩阵、样条、验证和诊断
版本	2026-07-27 · 基于真实数据验证结果

这本手册强调理解、复现与诚实验证。所有模型指标均来自真实的2023时间外测试集。

目录

章节按“核心路线—进阶加分—未来连接”组织。先完成核心路线，再根据时间深入。

目录	2
如何使用这本手册	3
项目要求、交付物与评分策略	4
四个Task的递进关系	5
Task 1：时空可视化是什么	6
Task 2：EOF分析是什么	7
Task 3：IDW预测是什么	8
Task 4：基函数线性回归是什么	9
为什么选择 bicycle.csv	10
研究问题、分析单位与目标变量	11
从高等代数和概率论进入模型	12
线性回归与设计矩阵	13
基函数：把一个变量变成一组可学习特征	14
B-spline：学习平滑的长期趋势	15
Fourier基函数：表示年度季节性	16
径向基函数：表示连续空间热点	17
社区指示基函数：学习稳定地点差异	18
Ridge正则化与偏差—方差权衡	19
为什么不能随机拆分时空数据	20
所需软件和项目文件夹	21
步骤1：导入并审计原始数据	22
步骤2：构造社区 × 月份面板	23
步骤3：完成Task 1时空可视化	24
步骤4：构造、拟合与验证模型	26
真实模型结果与解释	27
预测图、残差图与模型诊断	28
四页PPT逐页设计	29
答辩问题与推荐回答	30
局限性、伦理与不可推广范围	31
从本项目走向未来数据科学	32
从开始到提交的最终检查清单	33
资料与继续学习入口	34

核心路线

如何使用这本手册

这不是一份“复制代码就交作业”的答案，而是一条从已有数学基础进入时空数据科学的完整路线。第一次阅读先理解研究问题和四个Task；第二次按操作章节运行R；第三次根据真实输出制作四页PPT。

- 核心路线：项目必须理解和执行。
- 进阶加分：用于体现方法深度，但必须建立在核心路线正确之上。
- 未来连接：帮助你把本项目迁移到GAM、树模型和时空机器学习，现在不要求全部掌握。

五个检查问题

面对任何公式或代码，先问：数据是什么形状？输入是什么？输出是什么？模型相信什么结构？怎样用未见数据证明结果可信？

核心路线

项目要求、交付物与评分策略

原项目要求从四个数据集中选择一个，完成必做的Task 1时空可视化，再从Task 2 EOF、Task 3 IDW、Task 4基函数线性回归中选择一个。最终提交最多四页PowerPoint。

时空可视化	30%	图回答明确问题；时间、空间、颜色尺度和单位完整
选修方法	40%	原理正确；验证无泄漏；与基线比较；诚实解释局限
表达与逻辑	30%	研究问题贯穿数据、方法、结果和结论

最重要的策略

不要因为方法名字高级就堆模型。评分最高的路线是：研究问题清楚、方法和数据匹配、验证方式可信、四页之内讲得明白。

核心路线

四个Task的递进关系

Task 1是所有路线的共同起点：先看见规律和问题。三个选修Task分别把探索发展为模式分解、空间插值或解释与预测。它们没有绝对的新旧高低，关键是是否回答了正确的问题。

Task 1	数据在什么地方、什么时候发生什么变化？	地图、时间序列、热力图
Task 2	哪些共同空间模式解释了大部分变化？	EOF载荷、PC时间序列、方差比例
Task 3	没有观测的位置可能是多少？	IDW插值面、交叉验证误差
Task 4	时空结构能否解释并预测结果？	模型、预测、残差和测试指标

本项目的选择

选择Task 1 + Task 4，因为bicycle数据具有十年时间、固定社区位置和明确的未来预测问题。


核心路线

Task 1：时空可视化是什么

时空可视化不是把经纬度画成点，而是同时说明“在哪里、什么时候、数值多大、怎样变化”。它用于发现热点、趋势、季节性、异常、缺失和尺度问题，也是后续模型设计的证据。

时间序列	总体数量怎样随时间变化？	每月盗窃数与12个月移动趋势
季节箱线图	同一月份跨年份是否稳定？	一月至十二月分布
空间热点图	长期高值集中在哪里？	社区中心点大小和颜色
时空热力图	地点模式怎样随时间同步变化？	前25社区 × 月份

- 比较多张地图时必须固定颜色范围。
- 0表示记录数为零；NA表示没有观测，两者不能混淆。
- 热点是描述性结果，不等于该社区本身导致盗窃。
- 经纬度是社区中心点，不是每起案件的准确位置。



Task 1 示例：总体月度趋势与12个月移动平均。

完整解释

Task 2：EOF分析是什么

EOF把“时间 × 地点”矩阵压缩为少数主要空间模式和对应的的时间变化。它等价于对中心化的时空矩阵做PCA/SVD，最适合规则、较完整的空间面板。

X 的行是时间、列是地点； V 的每一列给出一个EOF空间模式； $U\Sigma$ 给出对应PC时间序列； Σ 中的奇异值决定解释方差比例。

- 中心化：减去每个地点的时间均值，关注偏离正常水平的共同变化。
- 标准化：只有在希望每个地点拥有相同权重时使用；否则会放大低方差地点。
- EOF正负号可以整体翻转，空间图和PC同时翻转后含义不变。
- EOF1解释方差最大，不等于因果最重要，也不自动具备预测能力。

适合的数据

COVID地点×日期或汇总后的bicycle社区×月份都可构造矩阵；缺失严重的Big Mac面板需要先处理缺期。

完整解释

Task 3 : IDW预测是什么

IDW (Inverse Distance Weighting) 根据附近已观测地点预测未观测地点。核心假设是空间上越近的地点越相似，因此距离较近的观测获得更大权重。

s 是目标地点， s_i 是已观测地点， d_i 是距离， p 控制距离衰减速度。 p 越大，预测越依赖最近地点。

- 必须留出部分已知地点，假装它们未知，再用RMSE/MAE评价。
- p 和邻居数量应通过交叉验证选择，而不是凭感觉。
- 大范围经纬度不能简单当平面坐标距离；需要投影或球面距离。
- IDW通常不给可靠不确定性，也不使用协方差结构。
- 自行车盗窃可能受商业区、交通和暴露量影响，不一定只由距离决定，因此不作为本项目主方法。

核心路线

Task 4 : 基函数线性回归是什么

普通直线只能表示固定斜率。基函数先把时间和空间坐标转换成一组更丰富的特征，再对这些特征做线性回归。模型对输入可以是弯曲、周期和局部的，但对待估系数仍然是线性的。

y 是社区 s 在月份 t 的盗窃数。 B_{trend} 表示长期趋势， B_{season} 表示季节周期， B_{space} 表示空间和社区差异。

B-spline	平滑且可局部弯曲	十年长期趋势
Fourier	周期性的正弦和余弦	每12个月重复的季节性
径向基函数	围绕空间中心逐渐衰减	连续空间热点
社区指示基函数	每个社区独立基线	稳定的社区差异

为什么选它

它严格符合Task 4，同时训练特征工程、设计矩阵、验证、正则化、诊断和解释，能够连接未来的数据科学学习。

核心路线

为什么选择 bicycle.csv

bicycle	31,833事件；140社区；10年；无缺失	重复行无ID；坐标为社区中心	最适合
covid	规则日期；可直接形成面板	仅51天；累计值修订；地理层级混杂	次选
bigmac	全球题材；连续价格	面板完整率约70.7%；日期歧义	清洗成本高
ufo	题材醒目；有城市坐标	日期歧义；报告偏差；事件稀疏	不推荐

bicycle的固定社区位置允许学习空间结构，120个月允许学习季节和长期趋势。汇总为社区×月份后，共有16,800个分析单元，足以比较简单基线与基函数模型。

不分析bike_cost的原因

核心问题是盗窃数量的时空变化。bike_cost包含1,623个非正值和少量极端值，加入会改变研究问题并增加不必要清洗。

核心路线

研究问题、分析单位与目标变量

研究问题：时空基函数能否预测不同社区的自行车盗窃数量，并揭示盗窃活动随空间、季节和长期时间的变化？

- 原始粒度：一行是一条被报告的盗窃事件。
- 建模粒度：一行是一个社区在一个月份的盗窃数量。
- 空间单位：140个社区及其中心经纬度。
- 时间单位：2014年1月至2023年12月，共120个月。
- 响应变量：theft_count；为减弱右偏，模型使用 $\log(1+\text{count})$ 。

解释边界

没有人口、自行车拥有量、通勤量或报案概率，因此结果描述的是“报告数量”，不能称为个人风险或因果效应。

核心路线

从高等代数和概率论进入模型

你已经学过的向量、矩阵、线性变换、期望、方差和协方差不是旁支，而是这个项目的语言。每个社区月份形成一行特征向量，所有行叠成设计矩阵 X ；系数向量 β 表示每个特征的权重。

X 是 $n \times p$ 设计矩阵， $n=16,800$ 个社区月份， p 是基函数个数； β 是 $p \times 1$ 系数； ϵ 是模型未解释的随机误差。

- 矩阵乘法：把多个基函数特征按系数组合成预测。
- 秩与共线性：列过于相似时，系数不稳定。
- 期望：模型预测可理解为给定特征后的平均水平。
- 方差：衡量结果波动，也连接到RMSE和偏差-方差权衡。
- 协方差：解释相邻月份或相邻地点为什么可能具有相关误差。

核心路线

线性回归与设计矩阵

“线性”指模型对系数 β 是线性的，而不要求输入变量只能原样进入。只要先计算好特征列，平方、正弦、样条或空间核都能成为 X 的一列。

最小二乘选择使残差平方和最小的系数。残差是实际值减预测值，不是原数据的误差标签。

y	$16,800 \times 1$	每个社区月份的 $\log(1 + \text{盗窃数})$
X	$16,800 \times p$	时间、季节、空间和社区基函数
β	$p \times 1$	每一列基函数的待估权重
$\hat{y}$	$16,800 \times 1$	模型预测，再用 $\exp(\hat{y}) - 1$ 还原

核心路线

基函数：把一个变量变成一组可学习特征


基函数 $\phi(x), \dots, \phi_K(x)$ 像一组积木。每一块有固定形状，模型学习怎样加权组合。这把“拟合一条复杂曲线”转化成“估计一组线性系数”。

ϕ_k 由我们选择， B_k 由数据估计。K太少会欠拟合，K太多可能过拟合，因此需要验证或正则化。

- 好处：非线性仍能使用成熟的线性代数和回归工具。
- 代价：基函数类型、数量和节点位置成为新的建模选择。
- 原则：每类基函数对应明确结构，而不是无限添加列。

Examples of temporal basis functions

B-splines represent smooth long-term change; sine/cosine terms represent seasonality



项目中的B-spline与Fourier基函数示例。

核心路线

B-spline：学习平滑的长期趋势

高次多项式在整个区间相互牵动，边界容易剧烈震荡。B-spline把时间区间分成若干段，每个基函数只在局部区域显著，因此既能弯曲又相对稳定。节点knots决定不同多项式片段连接的位置。

R代码

```
time_basis <- splines::bs(  
  panel$time_index,  
  knots = c(20, 39, 58, 77),  
  Boundary.knots = c(1, 120),  
  degree = 3  
)
```

- degree=3表示三次分段多项式。
- 节点从训练期确定；边界使用已知的项目月份范围，不使用未来盗窃值。
- 模型学习基函数权重，不直接把单个系数解释为某月增长率。
- 长期趋势图应展示组合后的效应，而不是逐个系数。

核心路线

Fourier基函数：表示年度季节性

自行车盗窃具有明显年度周期。月份类别需要11个参数且在十二月与一月之间不连续；正弦和余弦天然首尾相接，用少量参数表示平滑周期。

m 是一月至十二月。第一对表示一年一次的波动，第二对允许一年内出现更复杂的双峰或不对称形状。

R代码

```
sin1 <- sin(2*pi*month_of_year/12)
cos1 <- cos(2*pi*month_of_year/12)
sin2 <- sin(4*pi*month_of_year/12)
cos2 <- cos(4*pi*month_of_year/12)
```

与概率论的连接

这里不是假设盗窃服从正弦分布，而是把周期函数当作确定的特征列；随机性仍留在误差 ε 中。

核心路线

径向基函数：表示连续空间热点

径向基函数以某个空间中心为峰值，距离越远取值越小。多个中心的函数叠加后，可以形成平滑的空间表面。它比直接加入经纬度直线项更能表达局部热点。

s 是社区坐标， c_k 是第 k 个空间中心， σ 控制影响范围。 σ 太小会形成尖峰，太大会把城市抹平。

- 本项目从社区中心中均匀选取16个RBF中心。
- 经纬度先中心化并按共同尺度缩放，避免数值单位影响。
- RBF表达连续位置，但坐标仍只是社区中心。
- 如果目标是新城市或城市外外推，当前基函数不保证可靠。

进阶加分

社区指示基函数：学习稳定地点差异

第一版只使用连续空间RBF时，模型没有超过社区历史均值。原因是两个经纬度接近的社区仍可能因土地用途、商业活动或报案习惯而长期不同。于是加入每个社区的一系列0/1指示基函数。

如果观测属于社区 j ，该列为1，否则为0。这允许模型学习每个社区的稳定基线，同时保留季节和长期趋势。

重要取舍

社区指示基函数提升已知社区的预测，但无法直接预测训练中从未出现的新社区。因此它服务于“预测2023年现有140社区”，空间留出时应另用RBF-only模型做敏感性检查。

进阶加分

Ridge正则化与偏差一方差权衡

基函数增多后，部分列可能高度相关。Ridge在残差平方和之外惩罚大系数，使解更稳定。惩罚强度 λ 必须用验证集选择，不能看测试集后再调整。

$\lambda=0$ 退化为普通最小二乘； λ 越大，系数越接近0，模型越平滑但偏差可能增加。

真实结果中，2022验证选择的 λ 约为0.0001，接近无惩罚；2023测试RMSE中Basis OLS为2.05、Basis Ridge为2.06。这说明正则化作为稳健性工具有价值，但不能宣称它在本数据上优于OLS。

现代数据科学不是强迫复杂模型胜出

正确结论是：验证决定复杂度，测试集只做一次最终评价；如果简单模型更好，就选择或报告简单模型。

核心路线

为什么不能随机拆分时空数据

随机拆行会让同一社区的2023年1月进入训练、2月进入测试，模型等于提前看到了未来附近的信息。这会低估真实部署误差，属于数据泄漏。

训练集	2014–2021	估计模型与基础结构
验证集	2022	选择 λ 等超参数
测试集	2023	一次性报告最终泛化性能

- 时间验证始终用过去预测未来。
- 所有均值、节点、缩放参数和系数只能由训练数据得到。
- 测试集结果不好时不能返回修改模型再重测，否则测试集变成了验证集。
- 未来可使用rolling/sliding validation观察不同时段稳定性。

核心路线

所需软件和项目文件夹

R 4.6.1	数据整理、作图、模型	已检测
RStudio	运行和管理R项目	已安装
WPS Office	检查PDF、制作PPT	已安装
Poppler	渲染PDF逐页检查	Codex运行时提供

首次安装与每次加载

```
install.packages(c("tidyverse", "lubridate", "glmnet"))
library(tidyverse)
library(lubridate)
library(glmnet)
```

- R/：按顺序保存数据、作图和模型脚本。
- output/analysis/：审计、面板、指标和预测CSV。
- output/figures/：所有可复用图表。
- output/pdf/：最终教学手册。
- tests/：自动检查数据形状、无泄漏和PDF完整性。

核心路线

步骤1：导入并审计原始数据

R代码

```
bike <- readr::read_csv("bicycle.csv", show_col_types = FALSE)
bike <- bike |>
  mutate(date = as.Date(date),
         derived_quarter = paste0(year(date), 'Q', quarter(date)))
```

行数	31,833	保留全部事件
社区	140	作为固定空间单位
日期范围	2014-01-01至2023-12-31	形成120个月
缺失单元格	0	无需插补
与前行完全相同	1,475	无事件ID，不自动删除
quarter不一致	15,751	从date重新计算

为什么不删除重复行

同一日期、社区、位置类型和价格可能发生多起不同盗窃。没有唯一事件ID时，直接删除会把真实事件误判为重复。

核心路线

步骤2：构造社区 × 月份面板

原始数据是事件表，不能直接用一行表示一个固定时空单元。先按社区和月份计数，再补齐所有140×120组合。没有事件的组合补0，而不是NA。

R代码

```
panel <- bike |>
  mutate(month = floor_date(date, 'month')) |>
  count(neighborhood, month, name = 'theft_count') |>
  complete(neighborhood, month = all_months,
    fill = list(theft_count = 0))
```


- 最终行数必须是16,800。
- 每个社区必须恰好有120个月。
- 经纬度按社区连接，不能在计数后丢失。
- time_index从1到120；month_of_year从1到12。
- 模型响应使用 $\log_{1p}(\text{theft_count})$ ，预测后用 $\exp m1$ 还原并截断负数。

核心路线

步骤3：完成Task 1时空可视化

Seasonal distribution of bicycle thefts


Each box summarizes the same calendar month across 10 years




季节箱线图显示夏季明显高于冬季。

Long-run neighborhood theft hotspots

Points are neighborhood centroids; size and color show mean monthly count



空间热点集中于城市中心附近，但该图表示数量而非暴露校正风险。



前25个高值社区的时空热力图同时显示持续热点、季节性与年份变化。

- 先写一句每个点或色块代表什么。
- 再写图中最稳定的模式，而不是挑选单个极端点。
- 最后说明图对模型设计的影响：季节性支持Fourier，长期变化支持B-spline，热点支持空间基函数。

核心路线

步骤4：构造、拟合与验证模型

先构造训练期的基函数规则，再把同一规则应用到验证和测试。模型依次比较全局均值、社区均值、基函数OLS和基函数Ridge。这样能够证明复杂度是否真的带来额外价值。

R代码

```
train <- filter(panel, year <= 2021)
validation <- filter(panel, year == 2022)
test <- filter(panel, year == 2023)


x_train <- make_design_matrix(train, recipe)
ridge <- glmnet(x_train, log1p(train$theft_count), alpha = 0)
```

- λ 只用2022验证RMSE选择。
- 选择 λ 后用2014–2022重新拟合，再预测2023。
- 所有模型在完全相同的2023观测上计算MAE、RMSE和 R^2 。
- 模型比较必须包括简单基线。

核心路线

真实模型结果与解释

全局均值	2.19	4.17	-0.007
社区历史均值	1.41	2.73	0.569
基函数OLS	1.01	2.05	0.757
基函数Ridge	1.01	2.06	0.754



2023时间外测试：基函数模型明显优于两个均值基线。


基函数OLS相对社区均值基线把RMSE降低约25%，说明季节、长期趋势和空间/社区结构提供了历史均值之外的信息。Ridge没有进一步提升，说明当前设计矩阵在本任务上已较稳定。

怎样写结论


可以说“模型在2023测试集上具有更低预测误差”，不能说“这些变量导致盗窃”，也不能把测试 R^2 解释为对所有城市和未来年份都同样有效。

进阶加分

预测图、残差图与模型诊断



2023总体预测捕捉了季节形状，但低估了夏季峰值。



正残差表示实际盗窃高于预测，揭示模型仍未解释的局部热点。

- 峰值低估是平方误差模型和平滑基函数常见现象。
- 残差仍在中心区域聚集，说明土地用途、交通、人流等遗漏变量可能重要。
- 残差图不只是装饰；它检查模型是否系统性遗漏空间结构。
- 进一步可检查残差随时间、拟合值和社区的分布，但四页PPT只保留最关键证据。

核心路线

四页PPT逐页设计

1	问题与数据	研究问题、31,833事件、140社区、120个月、工作流
2	Task 1发现	趋势图、热点图、季节性与描述性发现
3	Task 4方法	基函数公式、训练/验证/测试、模型比较
4	预测与结论	预测/残差图、三条结论、局限和下一步

- 每页只回答一个问题，不把所有诊断都塞进展示。
- 字体至少18pt；图标题直接写发现，不只写变量名。
- 模型页必须出现简单基线和无泄漏时间切分。
- 结论页必须同时说模型做到了什么、没做到什么。

推荐叙事

看见明显季节与热点 → 用对应基函数编码结构 → 用过去预测2023 → 比基线更准但低估夏季峰值 → 得出有限、可信的结论。

进阶加分

答辩问题与推荐回答

为什么不随机拆分？	会把未来或相邻月份泄漏进训练，误差过于乐观。
为什么 $\log(1+y)$ ？	缓解右偏和极端峰值；预测后还原到计数尺度评价。
为什么既有RBF又有社区指标？	RBF学连续空间，社区指标学稳定但非平滑的地点差异。
Ridge为什么没赢？	验证选择接近零惩罚，说明当前任务无需强收缩；如实报告。
能否预测新社区？	包含社区指标的主模型不能直接外推；需用RBF-only空间模型。
这是因果模型吗？	不是；它描述和预测报告数量，未控制暴露量和混杂因素。

核心路线

局限性、伦理与不可推广范围

- 事件无唯一ID：1,475条完全相同行可能是真实多起事件，也可能含重复记录。
- 坐标是社区中心点：不能解释为案件发生的精确位置。
- 缺少暴露量：高数量可能部分来自人口、自行车拥有量或活动量更高。
- 报案偏差：数据描述被报告事件，不一定覆盖所有真实盗窃。
- 模型只测试2023：不能保证制度、疫情或城市结构变化后的稳定性。
- 热点展示可能造成社区污名化：使用中性语言，不把地点居民描述为原因。

正确措辞

写“报告的自行车盗窃数量在这些社区较高”，不要写“这些社区更危险”或“社区导致盗窃”。

未来连接

从本项目走向未来数据科学

基函数与线性模型	GAM、P-spline、趋势面回归	特征含义与平滑度验证
Ridge与验证	Lasso、Elastic Net、Boosting	超参数只用验证集
社区月份面板	随机森林、XGBoost	时空拆分和泄漏检查
空间RBF	Gaussian Process、Kriging	距离、尺度和不确定性
时间基函数	状态空间、LSTM	过去预测未来
残差地图	空间误差模型、GNN	检查遗漏的结构

真正可迁移的不是某个包名，而是：定义粒度、构造特征、建立基线、隔离测试集、选择指标、诊断残差、限制结论。这些原则在传统统计、机器学习和深度学习中都不会过时。

核心路线

从开始到提交的最终检查清单

- 研究问题能否用一句话说清？
- 一行数据代表什么？时间和空间单位是否明确？
- quarter是否从date重新计算？重复行是否说明而非武断删除？
- 四张Task 1图是否分别回答时间、季节、空间和时空问题？
- 每类基函数是否有明确原因？
- 训练、验证、测试是否严格按时间分开？
- 是否与至少两个简单基线比较？
- MAE、RMSE和 R^2 是否来自2023测试集？
- 是否展示预测和残差，而不只报最好分数？
- 结论是否避免因果化、风险化和过度推广？
- 四页PPT是否每页只有一个中心问题？
- R脚本能否从头运行并重新生成所有图表？

未来连接

资料与继续学习入口

- 原始任务：project.pdf。
- 原始数据：four_dataset/bicycle.csv。
- 本地知识库：矩阵与线性变换、特征值与特征向量、协方差与相关系数、PCA与SVD、R与时空数据入门、ggplot2与空间地图。
- R官方：splines::bs与predict.bs文档。
- R官方：mgcv smooth terms文档。
- tidymodels：sliding_window、sliding_index和sliding_period时间重采样。
- spatialsample：空间分块与leave-location-out验证。
- StatQuest：PCA、回归、正则化和模型评价视频。

学习顺序

先能解释设计矩阵和验证，再深入样条推导；先能复现实验和诊断，再追求更复杂模型。